

基于改进 Bilinear CNN 的细粒度图像分类方法^{*}

田佳鹭 邓立国

(沈阳师范大学数学与系统科学学院 沈阳 110034)

摘 要 为提高细粒度图像分类的精确度,提出一种基于双线性网络(Bilinear CNN)的改进方法。首先,选取结构紧密的 DenseNet121 卷积部分作为特征提取模块,运用改进的 Relu-and-Softplus 激活函数;接着,结合注意力机制引入空间注意力模块和通道注意力模块,在整体性和局部性上有效提取细节特征;并增加一层卷积层实现调整特征图维度的过渡作用,通过特征图分组策略有效降低特征向量维度减少参数;在双线性池化后采用全局最大池化层处理 N 个双线性特征向量,融合得到用于 Softmax 分类的最终向量。经实验证明,新模型的分类精确度可达到 96.869%,参数量也大幅度降低,工作效率显著提高。

关键词 细粒度分类;Bilinear CNN;注意力模块;分组策略;全局最大池化层

中图分类号 TP391.41;TP18 **DOI:**10.3969/j.issn.1672-9722.2021.05.022

Fine Grained Image Classification Method Based on Improved Bilinear CNN

TIAN Jialu DENG Liguu

(School of Mathematics and Systems Science, Shenyang Normal University, Shenyang 110034)

Abstract In order to improve the accuracy of fine-grained image classification, an improved method based on Bilinear CNN is proposed. First, DenseNet121 convolution part with tight structure is selected as the feature extraction module, and the improved Relu-and-SoftPlus activation function is used. Then, combining with the attention mechanism, the spatial attention module and the channel attention module are introduced to extract the detailed features effectively on the integral and local aspects. A convolutional layer is added to adjust the dimensionality of the feature map, and the feature map grouping strategy is adopted to effectively reduce the dimensionality of the feature vector and reduce the parameters. After bilinear pooling, N bilinear eigenvectors are processed by global maximum pooling layer, and the final vector for Softmax classification is obtained by fusion. The experimental results show that the classification accuracy of the new model can reach 96.869%, the number of parameters is also greatly reduced, and the working efficiency is significantly improved.

Key Words fine grained classification, Bilinear CNN, attention module, grouping strategy, global maximum pooling

Class Number TP391.41, TP18

1 引言

在目前图像识别领域中细粒度图像分类问题是研究的重点课题。细粒度分类是在大类别中进行子类别划分,由于物体类内差异细微、特征目标不突出因此分类难度大。相对而言粗粒度分类较

为简单,它只对物体作简单的类别区分特征较为明显。那么如何精准、高效地挖掘目标物体空间位置及其显著特征,是细粒度分类任务所要解决的关键问题。尽管以往的卷积神经网络已经能做到有效提取出物体的基本轮廓、细节描述等特征信息,但还不能将其完全应用于细粒度图像分类任务。双

^{*} 收稿日期:2020 年 10 月 12 日,修回日期:2020 年 11 月 15 日

基金项目:辽宁省教育科学规划课题“教育信息化云生态环境的架构大数据研究”(编号:JG16DB395);辽宁省教育厅高校科研项目“基于区块链智能合约健康医疗大数据价值转移和数据共享研究”(编号:LJC202008);国家社会科学基金艺术学重大项目(编号:18ZD23)资助。

作者简介:田佳鹭,女,硕士研究生,研究方向:人工智能、数据挖掘。邓立国,男,博士,副教授,研究方向:人工智能、数据库。

线性卷积神经网络(Bilinear CNN)基于它能有效提取较全面的特征信息,成为细粒度分类中的经典模型,其不足之处在于拥有过多的参数量、识别精度不够高等。因此,该文提出的改进模型着重针对上述问题,以 Bilinear CNN 作为基础模型引入注意力机制、分组策略以及新型 Relu-and-Softplus 激活函数。最终实验数据显示,新模型的预测精度更高可达 96.869%,涉及的参数量更少,模型性能较优。

2 双线性卷积神经网络的改进方法

2.1 DenseNet121

DenseNet121 是一种结构密集的卷积神经网络,由 4 个 Dense Block 和 3 个 Transition layer 共同组成。其中 Dense Block 为稠密连接模块,Transition layer 为两个相邻的 Dense Block 模块的衔接区域^[1]。并且 DenseNet 中每一个 Dense Block 块都融合前面所有层的信息,使得信息资源更丰富。其中 Dense Block 模块的结构为 BN+Relu+(1*1)Conv+BN+Relu+(3*3)Conv,使用维度为 1*1 的 bottleneck 卷积层可有效降低特征图的通道数以减少计算量。Transition layer 的结构为 BN+Relu+(1*1)Conv+(2*2)AvgPooling,其间使用了 1*1 维度的卷积层,用于维度的降低。

在 DenseNet121 神经网络模型中,任意两层之间直接相连,网络前面的每一层输出信息都会通过合并操作汇集到这一层,相应地该层学习得到的特征图信息,也会被传给后面的所有层。这正是与 ResNet 隔层相连思想最大的不同之处。描述 DenseNet 每一层的变换的式子如下^[2]:

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}]) \quad (1)$$

可以看出 DenseNet 模型结构较为简洁,它可综合利用多层复杂度较低的浅层特征来扩增信息量,使其得到一个具有较好泛化性能的决策函数,提高模型的抗过拟合性。

原始的 Bilinear CNN 模型采用两路的 VGG-16 作为特征提取模块,介于 DenseNet121 网络模型具有良好的性能和紧密的结构,将 DenseNet121 模型的卷积部分到最后一个卷积块为止,即去掉最后的 Global average pool 层和 Softmax 层作为改进模型结构中两路的特征提取模块^[3]。

2.2 Relu 的改进

模型中常用 Relu 激活函数,当 x 值小于 0 时函数值恒等于 0,当 x 值大于 0 时它是一个线性函数。根据函数的性质,它的优点是大于 0 时为线性函数,使网络具有一定的稀疏性,防止模型产生过

拟合现象;并且能通过良好的反向传播,防止梯度弥散现象发生^[4]。它的缺点是屏蔽了太多的特征信息,导致模型无法进行有效的学习。并且该函数恒等于 0 的特点,会导致大部分神经元可能永远不会被激活。Relu 激活函数表达式:

$$f(x) = \begin{cases} x & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (2)$$

另一个激活函数 Softplus,是一个不饱和的函数,与 Relu 激活函数相比更加平滑,因此 Softplus 可以称作 ReLu 激活函数的平滑版,但它不具有稀疏性这一特点^[5],函数表达式为

$$f(x) = \ln(e^x + 1) \quad (3)$$

该文提出的新激活函数,将 Relu 函数和 Softplus 函数相结合,取两者之长补两者之短,使其既有 Relu 函数稀疏性和快速收敛的特点,又具有 Softplus 函数平滑的特点。对于提出的新函数将其命名为 Relu-and-Softplus 函数,该函数由两部分组成以 $x=0$ 为分界点, $x \leq 0$ 的部分用 Softplus 函数的性质, $x > 0$ 部分则用到 Relu 函数的性质,最后将生成的 Relu-and-Softplus 函数整体向上平移 0.7 个单位量,表达式为

$$f(x) = \max[\ln(e^x + 1), x + 0.7] \quad (4)$$

如图 1 所示是 Relu-and-Softplus 激活函数。

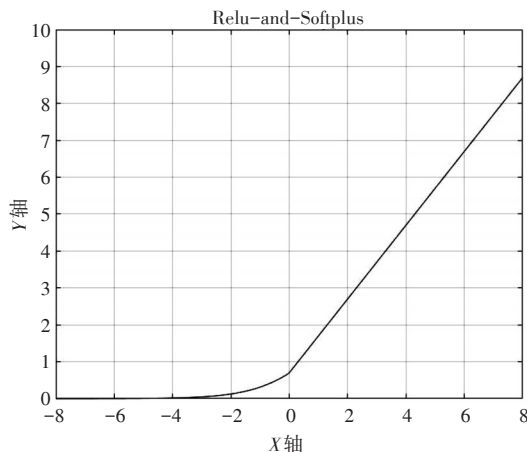


图 1 Relu-and-Softplus 激活函数

2.3 注意力模块

2.3.1 注意力机制

注意力机制的本质是在原有特征图的基础上添加一个权重掩码,代表特征的重要程度,强化重要的特征,抑制不必要的特征,提升网络的训练效率。在运算过程中通常使用软性注意力机制,即对于输入的 N 个信息,通过计算所有输入信息的加权平均值来确定信息的选取^[6]。在该机制下以概率 α_i 选择第 i 个信息的可能性表达公式为

$$\alpha_i = p(z=i|X, q) = \text{Soft max}(s(x_i, q)) = \frac{\exp(s(x_i, q))}{\sum_{j=1}^N \exp(s(x_j, q))} \quad (5)$$

其中, x_i 代表第 i 个信息的输入, q 是所要查询的信息, z 是一种注意力变量, $s(x_i, q)$ 是注意力的评分函数。通过计算得到注意力权重 α_i 后, 为完成对重要信息的提取工作将 α_i 与特征向量进行融合处理, 操作过程如下:

$$\text{Attention}(X, q) = \sum_{i=1}^N \alpha_i x_i \quad (6)$$

为提高模型分类精度, 引入注意力机制即通道注意力模块和空间注意力模块, 将两者分别构建在 DenseNet121 模型中最后一个卷积块即特征提取模块的后面, 使模型不仅关注到空间中每个重要特征, 又能获取到通道间相互的关联信息。将图像特征的整体性与局部性巧妙融合, 加深模型对图像特征的理解^[7]。

2.3.2 空间注意力模块

空间注意力模块主要于关注特征图上每个特征位置之间的相关性, 注重特征值的局部性。空间注意力模块处理过程为

1) 首先, 经过两个连续卷积层的处理实现对输入特征图下采样操作, 获取图像的特征编码;

2) 接着, 利用反卷积操作对特征编码上采样, 实现特征解码恢复到输入特征模块原有的维度, 但通道数变为 1;

3) 然后, 通过激活函数 Sigmoid 的运算将刚提取的位置信息矩阵转换为注意力掩码 A_s , 即每个特征值被映射至 0~1 之间生成权重值;

4) 保证注意力掩码和 DenseNet121 特征提取模块输出的特征图大小一致, 在这里还要将掩码部分 +1 后再与特征图点乘, 消除特征值可能会降低的问题, 处理完毕后进行后续的特征图与对应掩码的点乘运算使特征获得权重, 相融合后得到空间注意力特征图 X_s ;

5) 最后, 将原始特征图与空间注意力特征图 X_s 以用类似于 ResNet 残差网络中恒等的连接方式, 进行线性相加得到最终的模块输出 H 。

空间注意力模块处理的整体过程可用如式(7)表示:

$$H(x) = (1 + A_s(x)) \times G(x) \quad (7)$$

H 是模块的最终输出, 下角标 i 指代第 i 张图的输入, G 是 DenseNet121 特征提取模块输出的特

征向量, \times 运算符代表相乘运算。

2.3.3 通道注意力模块

通道注意力模块主要用于挖掘每一个特征图通道之间的相互关联性, 因此它更关注的是图像特征的整体性。通道注意力模块的处理过程。

1) 首先, 利用全局平均池化层(Global Average Pooling, GAP)提取特征图中每个通道大小为 1×1 的特征值, 以获得全局通道的特征信息, 并把它们拼接成一个特征向量;

2) 接着, 连接一个全连接层实现对特征向量的下采样操作, 实现信息的压缩, 紧接着再用一个全连接层对压缩的信息进行上采样, 实现维度的恢复;

3) 使用 Sigmoid 激活函数完成与空间注意力模块处理方式相同的特征映射操作, 生成通道注意力掩码向量 A_c ;

4) 接下来, 通过一个分支结构将原始输入的特征图快速传送到网络后面, 直接和通道注意力掩码向量 A_c 以对应元素相乘的方式, 为特征图的每个通道施予权重值实现特征融合, 得到通道注意力特征图 X_c ;

5) 最后, 将通道注意力特征图 X_c 与最初的原始特征图完成线性相加运算, 得到最终的模块输出 J 。空间注意力模块处理的整体过程用公式表示为

$$J_i(x) = (1 + A_c(x)) \times Q_i(x) \quad (8)$$

J 是模块的最终输出, 下角标 i 指代第 i 张图的输入, Q 是 DenseNet121 特征提取模块输出的特征图, \times 运算符表示对应元素相乘运算^[8]。

2.4 新增卷积层

DenseNet121 模型在两种注意力模块的帮助下完成特征提取后, 为符合后续分组双线性卷积策略的要求, 在注意力模块和分组双线性卷积之间增加一层新的卷积层, 使得特征图的通道维度变为 $N \times M$ 。此外, 卷积层的增加能够有效提高模型的特征提取效果和非线性变换能力, 新的卷积核大小为 3×3 , 卷积核数目为 $N \times M$, 步长为 1。其中 N 为分组的数目即数据集中拥有的类别数, M 是每个分组中包含的特征图数目。经该层的卷积后特征图的维度被调整为 $[A_1, B_1, (M \times N)]^{[9]}$ 。

2.5 分组策略

通常利用双线性池化操作后, 会得到二阶甚至高阶的特征使其包含更多的信息量, 但随着双线性特征向量维度的提升, 会使后续全连接操作或全局

最大池化操作的参数量急剧增加,运算负担过重,网络的训练难度提升^[10]。

分组策略是通过将卷积图进行分组,让每个组内部进行外积运算,这样得到的特征维度可极大降低,每个组对应的全局最大池化层的参数量也会因此下降。它的具体操作是对分组后每个类内特征图分别进行双线性池化融合,即运用外积运算分别得到各个类别的双线性特征,最后可以得到 N 个双线性特征向量。

对于改进的双新型卷积网络进行分组操作,通过新增的卷积层使特征图维度变为 $[A_1, B_1, (M \times N)]^{[11]}$ 。表示特征图被分 N 个组,并且每组含有 M 个维度为 $A_1 \times B_1$ 的特征图,这里设 M 为 4。

若将改进的模型从新增的卷积层处分为两部分,那么后半部分基于分组策略思想的双线性卷积模型形似于一个五元函数 $Q = F(f_{A,c}, f_{B,c}, M, P, L)$, 其中, $f_{A,c}, f_{B,c}$ 为特征提取函数, A 和 B 为二路卷积神经网络, c 表示第 c 组卷积图, M 为分组所包含的特征图数目^[12], P 表示池化函数, L 表示分类函数, 其中 f 也是一种映射函数, 即 $f: G \times I \rightarrow R^{S \times T}$, 表示为将输入图像 G 和它的原始尺寸 I 映射到 $S \times T$ 的空间范围中, S 代表生成特征图的分辨率大小, T 是通道数。此外, 特征提取函数应与 DenseNet121 当中的特征提取模块相对应。

假设 γ_c, λ_c 分别对应特征函数 $f_{A,c}, f_{B,c}$ 输出的第 c 个类别的特征图矩阵, 将相同维度的 γ_c, λ_c 进行外积运算, 即通过双线性池化操作完成特征融合, 得到双线性特征向量 Bilinear vector, 公式为^[13]

$$q(l, I, f_{A,c}, f_{B,c}) = f_{A,c}(I, E) \otimes f_{B,c}(I, E) = \gamma_c^T \lambda_c \quad (9)$$

其中 q 表示对双线性特征值进行外积运算函数, \otimes 符号表示外积操作, l 为图像直接对应的空间区域, E 表示输入图像。池化函数 P 通过累加每个位置的双线性特征, 进一步完善整体的特征描述信息, 计算公式如下:

$$x_c = \varphi(I) = \sum_{l \in S} q(l, I, f_{A,c}, f_{B,c}) \quad (10)$$

经过上式计算将双线性特征转变为向量 x_c , 接着进行向量规范化操作^[14], 即利于向量开平方运算计算得到向量 y_c , 接着再进行 L_2 正则归一化操作得到 z_c , 公式为

$$y_c = \text{sign}(x_c) \sqrt{|x_c|} \quad (11)$$

$$z_c = \frac{y_c}{\|y_c\|_2}$$

可以发现特征分组后的双线性特征向量维度

减小, 有利于减少后续计算的参数量, 提高训练效率。利用分组策略稍微会对模型的精确度有一定的影响, 但结合前面提出的注意力模块可以将这个问题很好的化解。

3 数据集准备

该论文为符合细粒度分类要求选取五类花作为基础数据集, 分别为 daisy、dandelion、roses、sunflowers、tulips 五种花。对于数据集的统一管理, 利用 TensorFlow 中提供的 TFRecord 格式, 将任意数据转化成能被 TensorFlow 处理的形式, 即以二进制文件格式使得图像中重要信息以及标签数据被整体的封装在一起, 用于后续模型训练^[15]。将数据集按功能分为包含大量数据的训练集和小部分数据的测试集, 其中测试集由每类中抽取的 100 张左右图片组成。训练集通过压缩编码被分为两个都含有 1000 张数据的 TFRecord 文件, 少量的测试集则装成一个 TFRecord 文件即可^[16]。图像被制作成 TFRecord 文件后的存储方式如图 2 所示。




图2 TFRecord 文件中的图片形式

五类花的数据集分配情况如表 1 所示。

表 1 五类花的数据集分配情况

Class-id	Flower Name	Train Images	Test Images
0	daisy	520	113
1	dandelion	700	198
2	roses	541	100
3	sunflowers	560	139
4	tulips	600	169

4 实验结果与分析

4.1 训练过程

对于改进模型, 在训练过程中我们把模型分成两个阶段来训练。首先锁定 DenseNet 神经网络的值, 使用训练集重点训练模型的后半部分, 并利用

DenseNet 曾经训练好的值对模型后半部分进行指导,因为经过训练的 DenseNet 已经包含了一定的信息量;当后面的权值训练到较稳定状态时,再解锁前半部分 DenseNet 的值,进行整体网络模型的训练,直至模型收敛并用测试集检验模型的训练情况。

4.2 实验结果

该文主要针对细粒度图像分类任务,基于 Bilinear CNN 模型改进其结构优化其性能,基础数据集选取五类花的数据。为验证改进的模型能够有效减少网络参数和计算量,提升模型训练效率,提高预测精确度。将改进的模型与 Bilinear CNN 模型、VGG 模型以及 ResNet 模型在参数量以及预测时间方面进行对比,如表 2 所示,可以发现新的模型结构所用的参数量较少,并且推理速度较快。

表 2 四种模型在参数量和预测时间方面的对比

模型名称	参数量(M)	预测时间(S)
改进的模型	49.982	0.689
Bilinear CNN(原始)	75.798	0.709
VGG	69.893	0.701
ResNet	65.665	0.699

此外,为了检验新模型的分类精确度,令四种模型在以相同的数据集为基础进行训练和识别,如表 3 所示,能够清晰地观察到,新模型相比其他三种模型具有较高的分类精确度,可高达 96.869%。通过以上检验能够证明,新的模型实现了改进目的,具有较好的性能,能有效应对细粒度图像分类的问题。

表 3 各种模型的分类精确度

模型名称	精确度
改进的模型	96.869%
Bilinear CNN(原始)	89.785%
VGG	91.668%
ResNet	92.623%

5 结语

该改进模型是一种针对细粒度图像分类问题的模型,为了改进原 Bilinear CNN 模型训练参数量过多,预测精度不够高的问题,提出了相应的改进措施。主要将结构紧密的 DenseNet121 模型作为双线性网络的特征提取模块;并改进激活函数为新型的 Relu+Softplus 函数;利用注意力机制生成空间注意力模块和通道注意力模块,以实现特征的整体性和局部性的完美结合;接着,利用分组策略有

效减少模型在 GMP 运算过程中的参数量,提升训练速度;并用全局最大池化层提取每个双线性特征向量的显著特征以实现最后的分类目的。经验证,新的模型无论是在训练效率还是分类精度方面较比其他模型都体现出优良的效果。因此,该模型能够很好地应对细粒度特征分类差异小的问题。对于今后的研究将在保证精确度的前提下,对模型的层次架构实现进一步的精简,以达到更好的性能。

参考文献

[1] 张家瑜,周迪斌,魏东亮,等. 基于双线性 CNN 与 Dense-Block 的导光板标记线缺陷检测[J]. 计算机系统应用, 2020,29(07):152-159.
ZHANG Jiayu, ZHOU Dibin, WEI Dongliang, et al. Defect detection of light guide plate marker line based on bilinear CNN and DenseBlock [J]. Computer System Applications, 2020, 29(07): 152-159.

[2] 彭慧玲. 基于 DenseNet 与 ResNeXt 算法的车牌定位识别方法研究[J]. 技术与市场, 2020, 27(10): 23-26.
PENG Huiling. Study on license Plate Location Recognition Method based on DenseNet and ResNeXt Algorithm [J]. Technology and Markets, 2020, 27(10): 23-26.

[3] 宋宇鹏,边继龙,安翔,等. 基于注意力机制的 DenseNet 模型的树种识别应用[J]. 实验室研究与探索, 2020, 39(7): 122-127, 173.
SONG Yupeng, BIAN Jilong, AN Xiang, et al. Application of DenseNet model for tree species identification based on attentional mechanism [J]. Laboratory research and exploration, 2020, 39(7): 122-127, 173.

[4] 廖牧鑫. 基于卷积神经网络的果实蝇细粒度图像分类研究[D]. 南昌:江西农业大学, 2019.
LIAO Muxin. A Study on the classification of fruit fly fine particle Images based on convolutional neural network [D]. Nanchang: Jiangxi Agricultural University, 2019.

[5] 赵馨宇,黄福珍,周晨旭. 基于 ReLU 稀疏性的 MAXOUT 卷积神经网络的数据分类算法[J]. 上海电力大学学报, 2020, 36(3): 280-284.
ZHAO Xinyu, HUANG Fuzhen, ZHOU Chenxu. Data classification algorithm of MAXOUT convolutional neural network based on ReLU sparseness [J]. Journal of Shanghai dianli university, 2020, 36(3): 280-284.

[6] 李小飞. 弱监督下基于对抗互补注意力机制和分层双线性池化的细粒度图像识别[D]. 南昌:江西师范大学, 2020.
LI Xiaofei. Fine-grained image recognition based on counter complementary attention mechanism and stratified bilinear pooling under weak supervision [D]. Nanchang: Ji-

(下转第 1017 页)

(工学版), 2017, 47(01): 268-273.

SHI Yaowu, CHEN Miao, SHAN Zetao, et al. Spatial direction smooth estimation of coherent signals based on feature space MUSIC algorithm[J]. Journal of Jilin University: Engineering, 2017, 47(01): 268-273.

[15] 赵谦, 董民, 梁文娟. DOA 估计算法的一种修正 MUSIC

算法的研究[J]. 计算机工程与应用, 2012, 48(10): 102-105.

ZHAO Qian, DONG Min, LIANG Wenjuan. Study on a Modified MUSIC Algorithm for DOA Estimation Algorithm[J]. Computer Engineering and Applications, 2012, 48(10): 102-105.

(上接第 981 页)

angxi Normal University, 2020.

[7] 李旭. 基于注意力机制的细粒度图像分类方法研究[D]. 保定: 河北农业大学, 2019.

LI Xu. Study on fine-grained image classification based on attentional mechanism [D]. Baoding: Hebei Agricultural University, 2019.

[8] XU Danqing, WU Yiquan. Improved YOLO-V3 with DenseNet for Multi-Scale Remote Sensing Target Detection[J]. Sensors, 2020, 20(15): 32-55.

[9] 王红霞, 周家奇, 辜承昊, 等. 用于图像分类的卷积神经网络中激活函数的设计[J]. 浙江大学学报(工学版), 2019, 53(7): 1363-1373.

WANG Hongxia, ZHOU Jiaqi, GU Chenghao, et al. Design of activation function in convolutional neural network for image classification [J]. Journal of Zhejiang University (Engineering Science Edition), 2019, 53 (7) : 1363-1373.

[10] 郝雪洁. 基于深度神经网络的细粒度图像分类方法研究[D]. 成都: 电子科技大学, 2020.

HAO Xuejie. Study on fine-grained image classification method based on deep Neural network [D]. Chengdu: University of Electronic Science and Technology of China, 2020.

[11] 王亚飞. 带注意力机制的车辆目标检测与识别[D]. 上海: 华东师范大学, 2020.

WANG Yafei. Vehicle target detection and recognition with attention mechanism [D]. Shanghai: East China Normal University, 2020.

[12] 严芳芳, 吴秦. 多通道融合分组卷积神经网络的人群计数算法[J]. 小型微型计算机系统, 2020, 41(10):

2200-2205.

YAN Fangfang, WU Qin. Crowd Counting Algorithm for multichannel fusion Grouping convolutional neural network [J]. Minicomputer Systems, 2020, 41 (10) : 2200-2205.

[13] 康一帅, 王敏. 基于分组卷积的密集连接网络研究[J]. 江苏科技大学学报(自然科学版), 2020, 34(01): 49-53.

KANG Yishuai, WANG Min. Research on dense connection network based on packet convolution [J]. Journal of Jiangsu University of Science and Technology (Natural Science Edition), 2020, 34(01): 49-53.

[14] 阳瑜, 吴小俊. 基于人脸标准化的纹理和光照保持 3D 人脸重构[J]. 模式识别与人工智能, 2019, 32(6): 557-568.

YANG Yu, WU Xiaojun. 3D face reconstruction based on face standardization for texture and light retention [J]. Pattern Recognition and Artificial Intelligence, 2019, 32(6): 557-568.

[15] 朱延刚. 基于多特征融合的花粉图像识别算法研究[D]. 南京: 南京信息工程大学, 2018.

ZHU Yangang. Research on pollen Image Recognition Algorithm based on multi-feature Fusion [D]. Nanjing: Nanjing University of Information Engineering, 2018.

[16] 彭雪. MOST 系列海量图像数据集的标准化问题研究[D]. 武汉: 华中科技大学, 2018.

PENG Xue. Research on standardization of MOST Series Mass Image Data Sets [D]. Wuhan: Huazhong University of Science and Technology, 2018.